# DOMÁCÍ ÚKOL NA BI-BIG

Vypracoval Matyáš Skalický 15.12.2018

## OBSAH

# ÚVOD

Cílem tohoto úkolu je zopakovat si postupy probrané na cvičení na vlastních datech.

# DATASET

Dataset obsahuje 550 000 záznamů z Black Friday z amerického obchodního řetězce. Obsahuje jak numerické, tak kategorické proměnné. Obsahuje chybějící hodnoty. Bylo dogenerován sloupec Refferal a upraveno Product_ID na numerickou hodnotu (odstraněním předpony P a úvodních nul). Úpravy datasetu jsou popsány v souboru DATASETTRANSFORM.IPYNB který se nachází v příloze. Dataset byl pro potřeby úkolu rozdělen na 3 části.

## ZDROJ DATASETU:

HTTPS://WWW.KAGGLE.COM/MEHDIDAG/BLACK-FRIDAY

## DATASET USERS.CSV

| User_ID | Gender | Age | Occupation | City_Category | Stay_In_Current_City_Years | Marital_Status | Refferal |
|---|---|---|---|---|---|---|---|
| 1000001 | F | 0-17 | 10 | A | 2 | 0 | www.baidu.com |
| 1000001 | F | 0-17 | 10 | A | 2 | 0 | www.samsung.com |
| 1000001 | F | 0-17 | 10 | A | 2 | 0 | www.google.com.ar |
| 1000001 | F | 0-17 | 10 | A | 2 | 0 | www.google.ca |
| 1000002 | M | 55+ | 16 | C | 4+ | 0 | www.accuweather.com |

```
RANGEINDEX: 537577 ENTRIES, 0 TO 537576
DATA COLUMNS (TOTAL 8 COLUMNS):
USER_ID                     537577 INT64  - UNIKÁTNÍ IDENTIFIKÁTOR UŽIVATELE.
GENDER                      537577 OBJECT - POHLAVÍ ZÁKAZNÍKA (M/F).
AGE                         537577 OBJECT - VĚKOVÁ SKUPINA ZÁKAZNÍKA.
OCCUPATION                  537577 INT64 - KATEGORIE DLE TYPU ZAMĚSTNÁNÍ (MASKOVANÁ, ČÍSLO).
CITY_CATEGORY               537577 OBJECT - KATEGORIE MĚSTA (MASKOVANÁ - HODNOTY A, B, C).
STAY_IN_CURRENT_CITY_YEARS  537577 OBJECT - DÉLKA POBYTU V SOUČASNÉM MĚSTĚ V LETECH.
MARITAL_STATUS              537577 INT64 - MANŽELSKÝ STATUS (1=ŽENATÝ, 0=JINAK).
REFFERAL                    537577 OBJECT - STRÁNKA, ODKUD UŽIVATEL PŘIŠEL, KDYŽ SE REGISTROVAL
MEMORY USAGE: 32.8+ MB
```

## DATASET PRODUCTS.CSV

| User_ID | Product_ID | Product_Category_1 | Product_Category_2 | Product_Category_3 |
|---|---|---|---|---|
| 1e+06 | 69042 | 3 | nan | nan |
| 1e+06 | 248942 | 1 | 6 | 14 |
| 1e+06 | 87842 | 12 | nan | nan |
| 1e+06 | 85442 | 12 | 14 | nan |
| 1e+06 | 285442 | 8 | nan | nan |

```
RANGEINDEX: 537577 ENTRIES, 0 TO 537576
DATA COLUMNS (TOTAL 5 COLUMNS):
USER_ID               537577 INT64 - UNIKÁTNÍ IDENTIFIKÁTOR UŽIVATELE.
PRODUCT_ID            537577 INT64 - UNIKÁTNÍ IDENTIFIKÁTOR PRODUKTU.
PRODUCT_CATEGORY_1    537577 FLOAT64 - PRIMÁRNÍ KATEGORIE PRODUKTU. (MASKOVANÁ, ČÍSLO)
PRODUCT_CATEGORY_2    370591 FLOAT64 - SEKUNDÁRNÍ KATEGORIE PRODUKTU. (MASKOVANÁ, ČÍSLO)
PRODUCT_CATEGORY_3    164278 FLOAT64 - TERCÉRNÍ KATEGORIE PRODUKTU. (MASKOVANÁ, ČÍSLO)
MEMORY USAGE: 20.5 MB
```

## DATASET USER_PURCHASE.CSV

| User_ID | Purchase |
|---|---|
| 1e+06 | 8370 |
| 1e+06 | 15200 |
| 1e+06 | 1422 |
| 1e+06 | 1057 |
| 1e+06 | 7969 |

```
RANGEINDEX: 537577 ENTRIES, 0 TO 537576
DATA COLUMNS (TOTAL 2 COLUMNS):
USER_ID     537577 NON-NULL INT64 - UNIKÁTNÍ IDENTIFIKÁTOR UŽIVATELE.
PURCHASE    537577 NON-NULL INT64 - PŘEDPOKLÁDÁM ŽE KUMULATIVNÍ SUMA ČÁSTKY UTRACENÉ UŽIVATELEM V OBCHODĚ.
DATASET NEOBSAHUJE INFORMACE O MĚNĚ.
MEMORY USAGE: 8.2 MB
```

# SPUŠTĚNÍ DATABÁZOVÉHO CLUSTERU

Následující postup vychází z NÁVODU PREZENTOVANÉHO NA 5. CVIČENÍ. Postup vyžaduje nainstalovaný a plně funkční DOCKER-COMPOSE.

## SPARK

### BUILD IMAGE PRO SPARK

Otevřeme terminál ve složce spark. Bude vytvořen image *spark* který bude využit dle parametrů při spuštění jak pro worker, tak pro master node.

```
DOCKER BUILD -F SPARK.DF -T SPARK .
```

### SPUŠTĚNÍ MASTER A WORKER NODE

```
DOCKER-COMPOSE UP
```

### SPARK-SHELL

#### SPUŠTĚNÍ SPARK-SHELL

Následující příkaz spustí kontejner s přístupem do bashe na popředí.

```
DOCKER RUN -IT -P 8088:8088 -P 8042:8042 -P 4041:4040 --NAME DRIVER -H DRIVER SPARK:LATEST BASH
```

### PŘIPOJENÍ SPARK-SHELL NA MASTER

V běžícím bashi kontejneru se připojíme na master node spark clusteru.

```
SPARK-SHELL --MASTER SPARK://<IP ADRESA MASTERA>:7077
```

## HDFS KONTEJNER

Pro spuštění kontejneru s Hadoop HDFS použijeme následující příkaz:

```
DOCKER RUN --NAME HADOOP -T -I SEQUENCEIQ/HADOOP-DOCKER /ETC/BOOTSTRAP.SH -BASH
```

Pro zjednodušení práce si přidáme do cesty image odkaz na hadoop.

```
EXPORT PATH=$PATH:/USR/LOCAL/HADOOP/BIN/
```

# IMPORT DAT DO DATABÁZOVÉHO CLUSTERU

Vytvoříme složku *data* v rootu hadoop image a v rootu HDFS filesystému.

```
MKDIR /DATA
HDFS DFS -MKDIR /DATA
```

Kopie dat do kontejneru na kterém běží HFDS.

```
DOCKER CP DATA/PRODUCTS.CSV HADOOP:/DATA/PRODUCTS.CSV
DOCKER CP DATA/USER_PURCHASE.CSV HADOOP:/DATA/USER_PURCHASE.CSV
DOCKER CP DATA/USERS.CSV HADOOP:/DATA/USERS.CSV
```

Vložení dat z filesystému image do HDFS.

```
HDFS DFS -PUT /DATA/PRODUCTS.CSV /DATA/PRODUCTS.CSV
HDFS DFS -PUT /DATA/USER_PURCHASE.CSV /DATA/USER_PURCHASE.CSV
HDFS DFS -PUT /DATA/USERS.CSV /DATA/USERS.CSV
```

Načtení csv souboru z HDFS do sparku

```
VAL USERS = SPARK.SQLCONTEXT.READ.FORMAT("CSV").OPTION("HEADER", "TRUE").OPTION("INFERSCHEMA", "TRUE").LOA
D("HDFS://172.17.0.5:9000/DATA/USERS.CSV")
VAL USER_PURCHASE = SPARK.SQLCONTEXT.READ.FORMAT("CSV").OPTION("HEADER", "TRUE").OPTION("INFERSCHEMA", "TR
UE").LOAD("HDFS://172.17.0.5:9000/DATA/USER_PURCHASE.CSV")
VAL PRODUCTS = SPARK.SQLCONTEXT.READ.FORMAT("CSV").OPTION("HEADER", "TRUE").OPTION("INFERSCHEMA", "TRUE").
LOAD("HDFS://172.17.0.5:9000/DATA/PRODUCTS.CSV")
```

# AGREGACE

## 1. VYTVOŘIT NOVÝ DATASET, KTERÝ BUDE AGREGOVAT DATA Z JEDNOHO PŮVODNÍHO DATASETU

Zjistíme, kolik maximálně uživatel utratil. Vzhledem k tomu, že přepokládám, že se jedná o kumulativní sumu tedy i kolik celkem v obchodě utratil.

```
// ZJISTÍME MAXIMÁLNÍ HODNOTY SLOUPCE PURCHASE
VAL USER_PURCHASE_MAX = USER_PURCHASE.GROUPBY("USER_ID").MAX("PURCHASE")
// ZOBRAZÍME VÝSLEDEK
USER_PURCHASE_MAX.SHOW()
```

## 2. VYTVOŘIT NOVÝ DATASET, KTERÝ BUDE AGREGOVAT DATA ZE DVOU PŮVODNÍCH DATASETŮ NAJEDNOU

Zjistíme, kteří zákazníci si koupili nejméně produktů

```
// REGISTRACE DATAFRAME JAKO SQL TABULEK
USERS.REGISTERTEMPTABLE("USERS")
PRODUCTS.REGISTERTEMPTABLE("PRODUCTS")

// SQL DOTAZ
VAL USERS_ORDER_COUNT = SPARK.SQLCONTEXT.SQL("SELECT USER_ID, FIRST_VALUE(GENDER) AS GENDER, FIRST_VALUE(AGE) AS A
GE, FIRST_VALUE(OCCUPATION) AS OCCUPATION, FIRST_VALUE(CITY_CATEGORY) AS CITY_CATEGORY, FIRST_VALUE(STAY_IN_CURREN
T_CITY_YEARS) AS STAY_IN_CURRENT_CITY_YEARS, FIRST_VALUE(MARITAL_STATUS) AS MARITAL_STATUS, FIRST_VALUE(REFFERAL)
AS REFFERAL, COUNT(PRODUCT_ID) AS PRODUCT_COUNT FROM USERS U FULL JOIN PRODUCTS P USING(USER_ID) GROUP BY USER_ID
ORDER BY PRODUCT_COUNT ASC")

// ZOBRAZÍME SI VÝSLEDEK. VOLÁNÍ PROVEDE DOTAZ.
USERS_ORDER_COUNT.SHOW()
```

## 3. VYTVOŘIT NOVÝ DATASET, KTERÝ BUDE AGREGOVAT DATA ZE DVOU DATASETŮ NAJEDNOU, Z ČEHOŽ JEDEN BUDE VÝSLEDKEM PŘEDCHOZÍ AGREGACE A ULOŽIT HO ZPĚT DO DATABÁZE/NA FILESYSTÉM

```
// REGISTRACE DATAFRAMU NA SQL TABULKU
USER_PURCHASE_MAX.WITHCOLUMNRENAMED("MAX(PURCHASE)",
"PURCHASE").REGISTERTEMPTABLE("USER_PURCHASE_MAX").
USERS_ORDER_COUNT.REGISTERTEMPTABLE("USERS_ORDER_COUNT")

// DOTAZ
VAL USER_AVERAGE_PURCHASE_AMOUNT = SPARK.SQLCONTEXT.SQL("SELECT USER_ID, PURCHASE / PRODUCT_COUNT AS
AVERAGE_PURCHASE FROM USERS_ORDER_COUNT U JOIN USER_PURCHASE_MAX USING (USER_ID) ORDER BY
AVERAGE_PURCHASE DESC")

// ZOBRAZÍME VÝSLEDEK
USER_AVERAGE_PURCHASE_AMOUNT.SHOW()
```

# EXPORT DAT ZE SPARK CLUSTERU

Na HDFS se vytvoří složka /data/users_order_count s výsledným csv.

```
USERS_ORDER_COUNT.COALESCE(1).WRITE.FORMAT("COM.DATABRICKS.SPARK.CSV").OPTION("HEADER","TRUE").SAVE("HDFS://172.17.0.5:9000/DATA/USERS_ORDER_COUNT")
```

Kopie dat z HDFS do filesystému kontejneru na kterém běží HDFS.

```
HDFS DFS -GET /DATA/USERS_ORDER_COUNT /DATA/USERS_ORDER_COUNT
```

Kopie dat z filesystému kontejneru do filesystému počítače.

```
DOCKER CP HADOOP:/DATA/USERS_ORDER_COUNT .
```

# VYHLEDÁVACÍ INDEX

## NAHRÁNÍ DAT A TVORBA INDEXU

Použijeme kontejner s technologií ElasticSearch pro indexaci csv souboru. Zároveň spustíme i kontejner Kibana, který slouží pro vizualizaci a dotazování nad daty. Data do ElasticSearch dostaneme za pomocí docker kontejneru LogStash. POSTUP VYCHÁZÍ ZE CVIČENÍ ČÍSLO 9.

Jdeme do složky logstash. Kontejnery spustíme na pozadí s použitím příkazu:

```
DOCKER-COMPOSE UP -D
```

Data se načtou dle definice konfigurace v souboru *logstash.conf*:

```
INPUT {
    FILE {
        PATH => "/DATASETS/BLACKFRIDAYEDIT.CSV"
        START_POSITION => "BEGINNING"
    }
}

FILTER {
    CSV {
        SEPARATOR => ","
        COLUMNS => ["USER_ID", "PRODUCT_ID", "GENDER", "AGE", "OCCUPATION", "CITY_CATEGORY", "STAY_IN_CURR
ENT_CITY_YEARS", "MARITAL_STATUS", "PRODUCT_CATEGORY_1", "PRODUCT_CATEGORY_2", "PRODUCT_CATEGORY_3", "PURC
HASE", "REFFERAL"]
    }
    MUTATE {CONVERT => ["USER_ID", "INTEGER"]}
    MUTATE {CONVERT => ["PRODUCT_ID", "INTEGER"]}
    MUTATE {CONVERT => ["OCCUPATION", "INTEGER"]}
    MUTATE {CONVERT => ["PRODUCT_CATEGORY_1", "INTEGER"]}
    MUTATE {CONVERT => ["PRODUCT_CATEGORY_2", "INTEGER"]}
    MUTATE {CONVERT => ["PRODUCT_CATEGORY_3", "INTEGER"]}
    MUTATE {CONVERT => ["PURCHASE", "INTEGER"]}
    }

OUTPUT {
    ELASTICSEARCH {
        HOSTS => "HTTP://ELASTICSEARCH:9200"
        INDEX => "BLACKFRIDAY"
    }
}
```

Uživatelské rozhraní Kibana je na adrese: HTTP://127.0.0.1:5601. Pro vytvoření indexu zvolíme *Management -> Index Patterns* a do pole “Index pattern” okopírujeme název indexu, tedy “blackfriday”. Následně klikneme next a v time filter zvolíme možnost “I don’t want to use Time Filter” jelikož náš dataset neobsahuje časové značky. Klikneme na Create index pattern a index je tak vytvořen.

# DOTAZY NA INDEX

Dotazy v Kibaně lze provádět v záložce *Discover*. Konzole se nachází na *Dev Tools -> Console*.

## FILTROVÁNÍ - VYHLEDÁNÍ VŠECH MUŽŮ:

Dev Tools:

```
GET /BLACKFRIDAY/DOC/_SEARCH
{
      "QUERY": {
            "MATCH": {
                  "GENDER": "M"
            }
      }
}
```

Kibana: `GENDER:M`

## TŘÍDĚNÍ - SEŘADIT ZÁKAZNÍKY PODLE ÚTRATY

Dev Tools:

```
GET /BLACKFRIDAY/DOC/_SEARCH
{
    "SORT": {
        "PURCHASE": {
            "ORDER": "DESC"
        }
    }
}
```

## WILDCARD HLEDÁNÍ - VŠICHNI ZÁKAZNÍCI CO PŘIŠLI Z GOOGLE

Dev Tools:

```
GET /BLACKFRIDAY/DOC/_SEARCH
{
    "QUERY": {
        "WILDCARD": {
            "REFFERAL": "WWW.GOOGLE.*"
        }
    }
}
```

Kibana: `REFFERAL:WWW.GOOGLE.*`

## DASHBOARD

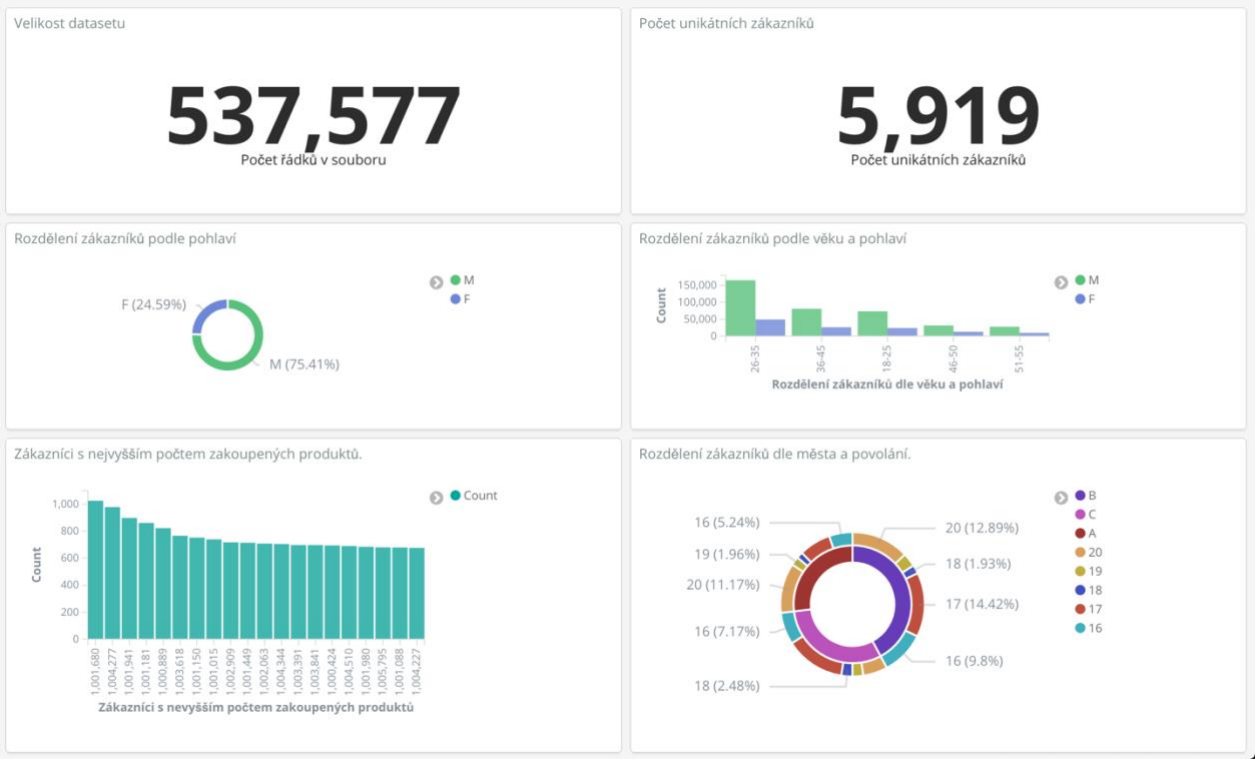


Export dashboardu je uložen ve formátu JSON v souboru dashboard_blackfriday.json ve složce logstash.

## ZÁVĚR

Vyzkoušel jsem si vytvořit vlastní Spark cluster s Hadoop HDFS úložištěm a následně ve spark-console udělat pár jednoduchých transformací. Dataset jsem taktéž importoval přes LogStash do ElasticSearch, vytvořil pár vyhledávacích dotazů a v Kibaně následně připravil dashboard s vizualizacemi. Vypracování úkolu mě moc nebavilo, protože jsem prováděl velmi podobné postupy jako na cvičení a v UseCasech. I tak mi tato semestrální práce zabrala větší množství času, než by mi připadalo užitečné. Mám pocit, že celá práce byla spíš než o big data o psaní dokumentace a o vymýšlení SQL dotazů. Radši bych svůj čas strávil děláním něčeho smysluplnějšího.